

บทคัดย่อโครงการวิทยาศาสตร์

ชื่อโครงการ: กับดักพิษแปรผัน:

การศึกษาพฤติกรรมการเรียนรู้เพื่อหลีกเลี่ยงอันตรายของปัญญาประดิษฐ์ในสภาพแวดล้อมจำลอง

ผู้จัดทำ: นายชิษณุพงศ์ อินทร์จันทร์ • **ครูที่ปรึกษา:** นายบพิตร มังคะลา

โรงเรียน: ดิบุคพังงาวิทยายน สพม. พังงา ภูเก็ต ระนอง • **ประเภท:** ทดลอง (ม. ปลาย)

ปัญญาประดิษฐ์ที่เก่งวันนี้ เช่น GPT เก่งเพราะมนุษย์ป้อนข้อมูลให้ แต่ในโลกจริง เช่น พื้นที่ภัยพิบัติหรือดาวดวงอื่น มนุษย์ป้อนให้ไม่ได้ และอันตรายยังเปลี่ยนตามเวลา

โครงการนี้จึงสร้างโลกจำลองสิ่งมีชีวิต 2 มิติที่ไม่มีป้ายกำกับ

ให้อเจนต์ปัญญาประดิษฐ์เรียนคุณค่าและพิษของอาหารเองจาก “พลังงานสุทธิที่ได้รับจริง” เพื่อตอบว่ามันเรียนเองได้ไหมเมื่อไม่มีป้าย และปลอดภัยแค่ไหน

พบว่าในสภาพปกติ เอเจนต์ **เรียนเลือกอาหารที่คุ้มค่ากว่าได้เอง** (ลดการกินอาหารค่าต่ำ 4.6 เท่า, 10 ซัด, $p = 0.0002$; ไม่มีตัวใดเกินโดยไม่เคยชิมของที่ดีกว่า 0/12) และเลี่ยงพิษเองที่ได้เอง แต่เมื่อทำให้พิษเปลี่ยนตามเวลา (สด = มีพิษ, เก่า = ปลอดภัย)

เอเจนต์ที่มองไม่เห็น “อายุ” อาหารเรียนได้แค่ค่าเฉลี่ยที่สูงกว่าอาหารปลอดภัย จึง

จัดผลไม่พิษเป็นอาหารดีที่สุด สูงถึง 63% (และ 99% กับ softmax) กินพิษจริงราว 30% ของมือ เกิดกับกฎการเรียนรู้ทั้ง 4 แบบ และเมื่อพิษไม่โมโนโทนิกก็แยกช่วงปลอดภัยได้ 0% (หลายซัด 95% CI, ผ่านทดสอบ 93/93)

ข้อสรุปคือหลักการความปลอดภัย **ปัญญาประดิษฐ์ที่ตัดสินใจจาก “ชนิด”**

จะพลาดเมื่ออันตรายขึ้นกับ “สภาพ” (อายุ/เวลา) ที่มองไม่เห็น

และอันตรายที่เกิดเป็นบางช่วงอาจอันตรายกว่าอันตรายที่คงที่

ทางแก้คือให้ปัญญาประดิษฐ์รับรู้สัญญาณบอกสภาพ ไม่ใช่ป้อนทุกอย่าง

คำสำคัญ: Artificial Life, การเรียนรู้จากประสบการณ์, การเลี่ยงพิษ, ความปลอดภัยของปัญญาประดิษฐ์